



Министерство науки и высшего образования Российской Федерации  
Федеральное государственное автономное образовательное учреждение  
высшего образования  
«Московский государственный технический университет  
имени Н.Э. Баумана  
(национальный исследовательский университет)»  
(МГТУ им. Н.Э. Баумана)

---

ФАКУЛЬТЕТ

ИУ «Информатика и системы управления»

---

КАФЕДРА

ИУ-1 «Системы автоматического управления»

---

Эргатические Системы

**Лабораторная работа №4**

**Обнаружение эпилептических приступов по ЭЭГ  
с использованием вейвлет-изображений и CNN**

Студент                      Канаан Хусейн

Группа                      ИУ1И-41М

Преподаватель          А.С. Кучин

2026 г

## **ВВЕДЕНИЕ**

Электроэнцефалография является одним из основных методов регистрации биоэлектрической активности головного мозга. Анализ ЭЭГ применяется при диагностике и наблюдении эпилепсии, однако ручная интерпретация длинных записей требует значительного времени и высокой квалификации специалиста. Поэтому актуальной является задача автоматизированного выделения фрагментов, соответствующих эпилептическим приступам.

ЭЭГ-сигнал относится к нестационарным временным рядам: его частотный состав изменяется во времени. В данной работе исходные фрагменты ЭЭГ были представлены в виде вейвлет-изображений, после чего задача распознавания была сведена к бинарной классификации изображений. Для решения использована сверточная нейронная сеть, позволяющая автоматически выделять информативные пространственные признаки.

## **ЦЕЛЬ И ПОСТАНОВКА ЗАДАЧИ**

Цель работы состоит в построении и оценке модели, классифицирующей ЭЭГ-фрагменты на два класса: наличие приступа и отсутствие приступа. В соответствии с заданием были подготовлены 50 записей с приступами и 50 записей без приступов, затем для каждой записи сформировано одно изображение на основе вейвлет-преобразования.

Основные этапы эксперимента включали: выбор и проверку исходных EDF-записей, выделение фрагментов сигнала, построение вейвлет-изображений, обучение сверточной нейронной сети и расчет метрик качества. В отчете рассматривается научная и методическая сторона эксперимента; технические

## ИСХОДНЫЕ ДАННЫЕ

В качестве источника использован открытый набор CHB-MIT Scalp EEG Database, размещенный на PhysioNet. Данные представлены в формате EDF и содержат многоканальные записи ЭЭГ пациентов с эпилептическими приступами. Для выполнения лабораторной работы был сформирован локальный поднабор из 100 файлов, достаточный для условия задачи.

Выборка содержит 50 записей класса «seizure» и 50 записей класса «non\_seizure». Используемые записи относятся к пациентам chb01, chb02, chb03, chb04, chb05, chb06, chb07, chb08, chb09, chb10, chb11. Все выбранные EDF-файлы были проверены на возможность чтения с помощью библиотеки MNE. Для всех файлов частота дискретизации составила 256 Гц. Сводные характеристики набора приведены в таблице 1.

Таблица 1 – Характеристика выбранных EDF-записей

| Показатель                       | Значение                          |
|----------------------------------|-----------------------------------|
| Количество файлов                | 100                               |
| Классы                           | seizure - 50; non_seizure - 50    |
| Частота дискретизации            | 256 Гц                            |
| Количество каналов в файлах      | 23: 94; 24: 5; 28: 1              |
| Продолжительность записей        | от 600 до 14427 с; медиана 3600 с |
| Суммарный объем выбранных файлов | 5.61 ГБ                           |

## ФОРМИРОВАНИЕ ВЕЙВЛЕТ-ИЗОБРАЖЕНИЙ

Для построения признакового представления из каждой записи выделялся фрагмент одного и того же канала ЭЭГ: FP1-F7. Для записей без приступов использовался участок 60-70 с. Для записей с приступами фрагмент выбирался внутри размеченного интервала приступа. Целевая длительность фрагмента составляла 10 с; для одного фрагмента длительность составила 9 с вследствие короткого интервала приступа.

Далее фрагменты преобразовывались в изображения с помощью непрерывного вейвлет-преобразования. Такое представление отражает изменение частотной структуры сигнала во времени и поэтому хорошо подходит для анализа нестационарных ЭЭГ. В результате было сформировано 100 PNG-изображений размером  $128 \times 128$  пикселей: 50 изображений класса «seizure» и 50 изображений класса «non\_seizure».

Использование изображения как промежуточного представления позволяет применить к задаче анализа ЭЭГ стандартные методы компьютерного зрения. Содержательно вейвлет-изображение можно рассматривать как карту активности сигнала во временно-масштабной области, где характерные изменения во время приступа должны отличаться от фоновых фрагментов.

Таблица 2 – Сформированный набор изображений

| Показатель              | Значение                  |
|-------------------------|---------------------------|
| Изображения seizure     | 50                        |
| Изображения non_seizure | 50                        |
| Использованный канал    | FP1-F7                    |
| Длительность фрагментов | 9 с - 1; 10 с - 99        |
| Размер изображения      | $128 \times 128$ пикселей |
| Формат                  | PNG                       |

## МОДЕЛЬ КЛАССИФИКАЦИИ

Для классификации использована последовательная сверточная нейронная сеть. Входом модели является цветное изображение размером  $128 \times 128 \times 3$ . Сверточная часть включает три блока Conv2D + MaxPooling2D, после чего применяется переход к векторному представлению, полносвязный слой, Dropout и выходной нейрон с сигмоидальной функцией активации.

Сеть обучалась как бинарный классификатор. Функцией потерь служила бинарная кросс-энтропия, оптимизатором - Adam, а основной метрикой - ассурасу. Общее количество параметров модели составило 826 529. Структура модели приведена в таблице 3.

Таблица 3 – Архитектура CNN

| Блок              | Состав                                                       |
|-------------------|--------------------------------------------------------------|
| Вход              | изображение $128 \times 128 \times 3$                        |
| Сверточный блок 1 | Conv2D(16, $3 \times 3$ , ReLU) + MaxPooling2D               |
| Сверточный блок 2 | Conv2D(32, $3 \times 3$ , ReLU) + MaxPooling2D               |
| Сверточный блок 3 | Conv2D(64, $3 \times 3$ , ReLU) + MaxPooling2D               |
| Классификатор     | Flatten + Dense(64, ReLU) + Dropout(0,4) + Dense(1, sigmoid) |

## РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТА

Набор данных был разделен на обучающую и тестовую части: 80 изображений использовались для обучения и 20 изображений - для тестирования. Обученная модель была сохранена в файл `models/eeg_seizure_cnn.h5`, а метрики качества - в файл `eeg_seizure_metrics.json`.

На тестовой выборке получена ассигасу = 0.75, значение функции потерь составило 0.5398. Матрица ошибок показывает, что модель правильно распознала 9 из 10 тестовых фрагментов с приступом и 6 из 10 фрагментов без приступа. Следовательно, полнота обнаружения приступов оказалась выше, чем полнота распознавания нормальных фрагментов.





Таблица 4 – Итоговые показатели качества

| Показатель                              | Значение           |
|-----------------------------------------|--------------------|
| Train / Test                            | 80 / 20            |
| Test accuracy                           | 0.75               |
| Test loss                               | 0.5398             |
| Матрица ошибок                          | [[6, 4], [1, 9]]   |
| Precision / Recall / F1 для non seizure | 0.86 / 0.60 / 0.71 |
| Precision / Recall / F1 для seizure     | 0.69 / 0.90 / 0.78 |

Для класса «seizure» полнота равна 0,90, что означает обнаружение большей части приступов в тестовой выборке. Для класса «non\_seizure» точность составила 0,86, но полнота равна 0,60. Это указывает на склонность модели относить часть нормальных фрагментов к классу приступа. В прикладном контексте такое поведение может быть приемлемым как начальный вариант, поскольку пропуск приступа обычно является более критичной ошибкой, чем ложное срабатывание.



## ОБСУЖДЕНИЕ

Полученный результат подтверждает применимость выбранной схемы: фрагмент ЭЭГ преобразуется в информативное двумерное представление, а затем классифицируется сверточной сетью. Точность 0,75 на тестовой выборке показывает, что даже простая CNN способна выявлять различия между вейвлет-образами приступов и фоновыми фрагментами.

Вместе с тем эксперимент имеет ограничения. Размер выборки невелик, поэтому метрики могут зависеть от конкретного разбиения данных. Также использовался только один канал ЭЭГ, тогда как полноценный анализ обычно опирается на несколько каналов. Для дальнейшего улучшения следует увеличить число фрагментов, применить *patient-aware split*, использовать многоканальные признаки и выполнить подбор гиперпараметров.

## ЗАКЛЮЧЕНИЕ

В работе реализован полный учебный конвейер автоматического распознавания эпилептических приступов по ЭЭГ: от подготовки размеченных фрагментов до обучения и оценки нейросетевой модели. Сформировано 100 вейвлет-изображений, построена сверточная нейронная сеть и получена итоговая точность 0,75 на тестовой выборке.

Результаты показывают, что сочетание вейвлет-преобразования и CNN является работоспособным подходом для первичного анализа ЭЭГ. Несмотря на ограничения небольшого набора данных, эксперимент демонстрирует корректную методологию обработки биомедицинских временных рядов и может служить основой для дальнейшего расширения модели.